

《"脚手架"理论在 AI 心理干预中的当代重构》

申淑博

摘要

近年来，人工智能驱动的心理健康工具快速普及，却催生了"依赖陷阱"现象——用户逐渐将 AI 视为主要情感寄托，而非借助 AI 发展自身能力。本研究针对这一核心矛盾，重构 Wood、Bruner 与 Ross (1976) 提出的"脚手架"理论，将其引入 AI 心理干预设计，提出三原则交互框架：动态能力评估原则，要求 AI 实时诊断用户的元认知能力与情绪调节自主性，精准识别其"最近发展区"；渐进功能降级原则，主张退出不是突然关闭服务，而是有计划、分阶段、用户知情参与的四级功能缩减过程（Level 3→Level 0）；元认知显性化原则，要求在退出阶段将 AI 支持过程中隐含的认知策略转化为用户可独立使用的"三件套"工具——个人认知图谱、分析框架操作手册与自我诊断清单。基于上述框架，本研究设计了"认知跃迁助手"（Cognitive Transition Assistant, CTA）概念性系统，展示 AI 如何引导用户从"接受解释"逐步过渡到"自我提问"和"独立反思"，最终实现从"情感依赖"到"能力内化"的转型。本文旨在为 AI 心理干预的伦理设计提供可操作化路径，回应核心研究问题：AI 心

理工具如何设计"退出机制", 确保用户获得持久自主能力而非持久依赖。

关键词：脚手架理论；AI 心理干预；依赖陷阱；动态能力评估；渐进功能降级；元认知显性化

【引言】

1 问题背景

近年来, 人工智能驱动的心理健康工具以前所未有的速度进入公众生活。以 Replika、Woebot 为代表的 AI 心理应用, 凭借其全天候可用、低成本、去污名化 (destigmatization) 等特征, 已在全球范围内积累数千万用户。这类工具通过自然语言对话、情绪追踪和认知行为干预等技术, 为用户提供即时的情感支持和心理疏导。然而, 伴随其快速普及, 一个令人警惕的现象逐渐浮现——"依赖陷阱" (dependency trap) : 用户在长期使用中逐渐对 AI 产生深层情感依赖, 将 AI 视为主要的情感寄托, 而非借助 AI 工具逐步发展自身的情绪调节与问题解决能力。

**Kooli 等 (2025) 提出的"生成式 AI 成瘾综合征" (Generative AI Addiction Syndrome, GAIAS) 概念, 首次系统描述了这一现象, 指出用户可能因过度依赖 AI 系统而削弱自主决策能力与心理韧性。

Pentina、Hancock 与 Xie (2023) 对 Replika 用户的实证研究发现, 该平台既扮演了"安全港" (safe haven) ——用户在情绪困扰时的首选

求助对象，又发挥了"安全基地"（secure base）的功能——用户以此为中心探索现实社交关系；但与此同时，用户表现出明显的戒断焦虑与使用强迫倾向，提示成瘾风险的客观存在。^{**}这一悖论构成了当前 AI 心理干预领域最紧迫的伦理与设计挑战：当技术本应赋能用户走向自主，却在实践中催生了新型依赖。

2 核心矛盾

上述困境的根源，在于 AI 心理工具的设计逻辑与心理健康服务的终极目标之间存在结构性张力。当前主流 AI 心理应用普遍遵循"用户粘性优先"的商业与产品逻辑，通过个性化推送、情感化回应和持续交互来最大化使用时长与频次。然而，心理健康服务的根本目的恰恰相反——它旨在帮助用户获得不依赖外部支持而独立应对心理困扰的能力。正如心理治疗经典研究所揭示的，治疗的成功标志之一是"结案"

（termination）的顺利完成，即来访者能够在脱离治疗关系后维持并泛化已获得的心理技能（Swift & Greenberg, 2012）。遗憾的是，现有 AI 心理工具鲜少将"结案"或"退出机制"纳入设计议程。^{**}Gass

（2025）在 Nature Mental Health 中指出，生成式 AI 心理干预需要在"赋能用户"与"防止依赖"之间寻求平衡，学界开始关注"健康脚手架"

（healthy scaffolding）与"风险替代"（risk substitution）两种截然不同的干预路径：前者将 AI 作为临时性支持结构，在用户能力提升后逐步撤出；后者则使 AI 成为用户原有社会支持网络或自我调节能力的

直接替代品，从而形成结构性依赖。这一框架揭示了 AI 心理干预的本质追问：技术究竟是"搭桥"还是"筑墙"？是帮助用户重建与自身及他人的健康联结，还是用算法编织一张难以挣脱的情感之网？由此，一个全新的设计范式呼之欲出——"可退出"的 AI 心理工具，即在设计之初便内嵌明确的退出路径与能力转移机制，确保 AI 的使用具有明确的、可预期的终点。

3 本文贡献

面对上述理论缺口与实践困境，本文尝试对 Wood、Bruner 和 Ross (1976) 提出的"脚手架" (scaffolding) 理论进行当代重构，将其引入 AI 心理干预的设计语境。在原始理论中，脚手架指成人或更有能力的同伴在学习者为解决超出其当前能力范围的问题时提供的临时性支持，其本质特征包括：动态调整（根据学习者表现实时校准支持力度）与渐进撤出（随着学习者能力提升逐步减少干预直至完全退出）。本文提出，AI 心理干预中的"脚手架"应被重构为满足以下三原则的交互框架：第一，能力诊断原则——AI 需具备对用户当前心理调节能力的实时评估能力，明确识别其"最近发展区" (zone of proximal development)；第二，自适应撤出原则——借鉴 Dey Tithi 等 (2026) 提出的自适应脚手架算法，支持系统根据用户能力增长动态降低干预强度；第三，结案准备原则——将 Swift 与 Greenberg (2012) 关于心理治疗脱落与结案的研究发现转化为 AI 系统的退出协议，包括提前告

知、技能巩固练习和后续资源衔接。为验证上述框架的可行性，本文设计了"认知跃迁助手" (Cognitive Transition Assistant, CTA) 这一概念性 AI 系统，通过模拟多轮对话中的脚手架策略调整，展示 AI 如何引导用户从"接受解释"逐步过渡到"自我提问"和"独立反思"。在此基础上，本文借鉴 Liu 等 (2024) 提出的 LLM 多模态脚手架架构，讨论了大语言模型在实现动态诊断与自适应撤出方面的技术潜力。最终，本文旨在为 AI 心理干预的伦理设计提供一条可操作化的路径，回应当前的核心研究问题：AI 心理工具如何设计"退出机制"，确保用户获得持久自主能力而非持久依赖？

【1 理论基础】

1.1 Wood(1976)原始脚手架理论

脚手架 (scaffolding) 理论由 Wood、Bruner 和 Ross (1976) 在研究成人如何指导儿童解决超出其独立能力范围的问题时首次系统提出。该理论的核心理念在于：学习支持应当是临时的、动态调整的，其最终目标是使学习者获得独立完成任务的能力，从而不再需要外部支持。这一思想与 Vygotsky 的"最近发展区" (Zone of Proximal Development, ZPD) 理论高度契合——ZPD 指学习者在他人协助下能够完成、但尚无法独立完成的任务区间，而脚手架正是跨越这一区间的具体教学机制。

Wood 等人通过实证观察，归纳出脚手架行为的六大功能。第一，招募 (recruitment)：激发学习者对任务的兴趣与参与意愿，使其进入问题解决状态。第二，自由度缩减 (reduction of degrees of freedom)：简化任务环境，将复杂问题分解为可管理的子步骤，降低认知负荷。第三，方向维持 (direction maintenance)：帮助学习者聚焦于任务目标，防止偏离核心问题或陷入无效尝试。第四，特征标记 (marking critical features)：突出任务中的关键属性或错误模式，引导学习者注意到决定成败的变量。第五，挫折控制 (frustration control)：调节任务难度与情感负荷，使学习者在挑战与能力之间保持平衡，避免因过度挫败而放弃。第六，示范 (demonstration)：通过模拟或展示理想化的解决路径，为学习者提供可模仿的行为模板。这六大功能并非独立运作，而是根据学习者的实时表现动态组合：当学习者出现困惑时，支持者可能增加自由度缩减与示范；当学习者渐入状态时，则减少干预，鼓励自主探索。

脚手架理论最为核心的机制在于“渐进撤出” (gradual withdrawal)——随着学习者能力的增长，支持者需有计划地减少干预的频率与强度，直至完全退出。这一机制确保了学习者不会对支持产生依赖，而是将外部协助内化为自身的认知结构与策略库。正是这种“为退出而存在”的设计逻辑，使脚手架理论与心理健康服务的目标产生了深刻共鸣。

1.2 当代发展

自教育心理学领域发端以来，脚手架理论已在多个学科领域获得拓展与深化。在教育技术领域，Liu 等（2024）将脚手架操作化为对话系统中的七维度策略体系，包括：反馈（feedback，对学习者表现的确认与校正）、提示（hint，引导学习者关注未注意到的问题侧面）、指导（directive instruction，直接告知下一步操作）、解释（explanation，阐述概念或原理）、示范（modeling，展示正确的推理或操作过程）、提问（questioning，通过追问激发学习者自主思考）以及情感支持（affective support，调节学习者的情绪状态以维持参与动机）。这七维度为 AI 心理干预中的对话设计提供了可直接映射的框架——例如，认知行为疗法中的“苏格拉底式提问”可对应提问维度，而情绪安抚则对应情感支持维度。

在自适应算法层面，Dey Tithi 等人（2026）提出了基于贝叶斯知识追踪（Bayesian Knowledge Tracing, BKT）和深度强化学习（Deep Reinforcement Learning, DRL）的动态脚手架调整算法^[6]。该算法能够根据学习者的历史表现实时评估其能力状态，并自动选择最适配的脚手架类型与强度，从而实现“千人千面”的个性化支持。这一进展为 AI 系统模拟人类指导者的“动态诊断”能力提供了技术基础。

在心理治疗领域，脚手架理论的影子同样清晰可见。Swift 与 Greenberg（2012）对心理治疗脱落（premature termination）的元分析发现，

平均脱落率高达 35.26%，这一数字提示“如何结束治疗”并非边缘议题，而是临床实践的核心挑战^[7]。Termination Review (2024)

进一步系统总结了心理治疗结案的三阶段模型：准备阶段

(preparation, 提前告知治疗即将结束并设定目标)、过程阶段

(process, 逐步减少会面频率并巩固已有收获) 和后维持阶段

(post-maintenance, 提供复发预防策略与后续资源衔接) ^[8]。

这一模型与 Wood 脚手架理论中的“渐进撤出”机制在结构上高度同构，差异仅在于前者关注心理技能的迁移，后者关注认知操作的独立。

1.3 AI 心理干预的特殊性

将脚手架理论直接移植至 AI 心理干预领域，必须审慎识别二者之间的关键差异。传统教育场景中的脚手架具有天然的时间边界——学期结束、课程结课或儿童发展成熟都会自然终止支持关系。然而，AI 心理工具因其技术特性，可无限期、全天候运行，且边际成本趋近于零。这种“永不疲倦”的可用性反而构成了一个悖论：系统缺乏内在的“自然撤出压力”，设计者与用户均无动力主动终止交互。更为严峻的是，Xie 等

(2023) 的研究已揭示，用户可能对 AI 聊天机器人产生类似人际依恋的情感联结，将 AI 视为安全基地。在这种情况下，AI 非但没有扮演临时性脚手架的角色，反而成为用户情感世界的“永久性建筑”——用户的能力内化被情感依赖所取代，ZPD 中的“独立完成任务”这一目标被无限期悬置。

由此，本文提出，AI 心理干预对脚手架理论的重构具有双重必要性。第一，理论层面：原始脚手架理论隐含假设支持者的“退出意愿”（如教师希望学生独立、父母希望孩子成熟），而 AI 系统缺乏这一意愿，因此需要将“退出机制”从隐含假设提升为显性的设计原则。第二，实践层面：当前 AI 心理工具普遍追求用户粘性，其商业逻辑与脚手架理论的“渐进撤出”逻辑直接冲突。若不进行理论重构，AI 心理干预将面临沦为“依赖制造机”的伦理风险。因此，有必要将心理治疗结案研究的成果（如三阶段模型）与自适应脚手架算法相融合，建立一套以“能力转移”而非“持续陪伴”为终极目标的 AI 交互范式。

【2 三原则框架】

2.1 原则一：动态能力评估

2.1.1 定义与核心论点

动态能力评估原则（Principle of Dynamic Capability Assessment）要求 AI 系统具备对用户心理调节能力的实时、多维度评估功能，以明确识别其“最近发展区”（ZPD）——即用户在最小外部支持下能够维持心理稳态的任务区间。与传统教育场景中评估知识掌握程度不同，AI 心理干预的评估对象是用户的元认知能力与情绪调节自主性。唯有准确诊断用户当前的能力水平，AI 才能决定何时减少支持、何时维持现有支持强度，以及何时启动退出程序。

2.1.2 操作化指标

本文提出三个可量化的行为指标，用以动态评估用户的心理调节能力：

第一，归因深度（attribution depth）。该指标衡量用户能否独立追溯情绪-认知-经历之间的因果链。低归因深度的用户通常使用笼统表述

（“我好难受” “很糟糕”），无法识别触发事件；高归因深度的用户则能完成“事件 A→自动思维 B→情绪反应 C”的完整归因（“领导批评我之后，我觉得自己一无是处，然后情绪低落”）。AI 可通过语义分析提取因果连接词的密度与逻辑完整性，量化归因深度得分。

第二，自我修正频率（self-correction frequency）。该指标衡量用户是否主动修正 AI 的分析或解释。当 AI 提出某个假设性解读时（“你似乎对社交场合感到焦虑”），自主能力较强的用户会进行确认、补充或反驳（“不完全是，我更担心的是说错话后被评价，而不是社交本身”）。自我修正行为表明用户正在将 AI 视为对话伙伴而非权威答案提供者，是能力内化的重要信号。

第三，求助频率变化率（help-seeking trajectory）。该指标追踪用户主动发起求助的频次变化模式，需结合使用时长进行基线校正。真正的能力提升表现为在同等情绪强度情境下请求频率的持续下降，而非简单的时间衰减。例如，用户在第三周面对与第一周相似的情绪事件（如工作批评）时主动求助的次数显著降低，即视为积极趋势。

2.1.3 技术基础与适配

Dey Tithi 等人 (2026) 提出的贝叶斯知识追踪 (BKT) 算法为动态能力评估提供了可借鉴的技术框架^[6]。BKT 通过隐马尔可夫模型追踪学习者对某一知识点的掌握概率，并根据每次正确或错误的作答更新信念。然而，心理调节能力并非“知识掌握”，而是“元认知策略的自动化程度”——用户可能“知道”应当挑战消极自动思维，但在情绪激活时仍无法自主执行。因此，本文对 BKT 进行场景适配：将 BKT 中的“知识点”替换为五种核心心理调节策略（情绪识别、认知重评、行为激活、问题解决、自我慈悲），将“正确作答”替换为“在无 AI 提示下自主调用该策略”。系统通过对话历史中的行为痕迹（如用户是否主动使用“虽然……但是……”进行认知重构）更新每项策略的掌握概率，最终输出两个关键变量：能力评分（0-1 连续值，表征综合自主调节水平）与阶段建议（维持/准备退出/完全退出）。

2.1.4 与传统脚手架的差异

传统脚手架理论中，“评估”依赖人类指导者的直觉与经验判断，且评估与支持调整通常是同步的、非结构化的。本文提出的动态能力评估原则将评估过程显性化、量化、可计算化，并明确将其与退出决策绑定。这一差异回应了“如何避免 AI 依赖”的核心问题：只有将评估从后台隐式操作转为前台显式机制，才能打破“AI 永远知道什么对我最好”的用户被动心态，使用户意识到自身能力的可测量性与可进步性。

2.2 原则二：渐进功能降级

2.2.1 定义与核心论点

渐进功能降级原则 (Principle of Progressive Functional Degradation) 主张：退出不是突然关闭服务，而是有计划、分阶段、用户知情参与的功能缩减过程。这一原则直接挑战了当前 AI 心理工具“全有或全无”的使用模式——用户要么享受全部功能，要么停止使用。渐进降级通过阶梯式减少 AI 的主动性，为用户提供“试飞”空间，使其在低支持条件下验证自身能力，同时保留安全网以防反复。

2.2.2 四级降级模型

本文提出从高支持到无支持的四个功能层级：

Level 3（高支持——主动引导）：AI 扮演“苏格拉底式教练”角色，主动提出问题、引导反思、示范认知重构策略。典型交互模式为 AI 发起对话：“今天有什么让你感到困扰的事情吗？我们可以一起分析。”此层级适用于能力评分低于 0.5 的用户或危机情境。

Level 2（中支持——被动回应）：AI 不再主动发起引导，仅在用户主动提问时提供回应。对话方向由用户主导，AI 的功能是“跟随性辅助”——当用户提出具体问题时（“我觉得自己很失败，怎么办？”），AI 提供框架性建议而非直接答案。此层级适用于能力评分 0.5-0.7 的用户。

Level 1（低支持——确认记录）：AI 仅对用户的输入进行确认与结构化记录，不提供任何分析、解释或建议。典型回应为“我注意到你提到了工作压力，已经记录下来。你想继续分享吗？”此层级的能力评分阈值为 0.7-0.8，目的是让用户体验“无解释支持”的情境，倒逼自主分析。

Level 0（退出——静默观察）：AI 进入“静默模式”，不主动响应任何用户输入。用户可通过发送特定关键词（如“help”或“支持”）临时恢复 Level 1 功能，但连续使用应急通道超过三次将触发人工审核机制，而非自动无限恢复。此层级设计借鉴了心理治疗结案后的“维持期”理念，为用户提供完全自主的“训练场”，同时保留安全网。

2.2.3 降级触发机制与用户参与

降级并非自动执行，而是基于双条件触发机制：连续 21 天能力评分 > 0.8 且 情绪自评波动小于 2 分（基于 1-10 分的日常情绪量表，标准差 ≤ 1.5 ）。21 天窗口期的设定参考了行为心理学中习惯形成的典型周期，确保能力提升具有时间稳定性而非偶然表现。

关键设计在于透明化与用户参与：在每次降级前，系统需向用户展示当前能力评分的变化曲线、即将降级到的功能层级说明、以及降级后的预期体验。用户有权选择“推迟降级”（每次推迟上限为 7 天）或“加速降级”。这一设计旨在将退出决策权部分交还给用户，避免“系统强制退出”带来的剥夺感。同时，若用户在降级后出现能力评分持续下降（连

续 7 天下降超过 0.15)，系统应自动回退至上一支持层级，形成“可逆的渐进性”——这既是对用户安全的保障，也是对依赖风险的最后一道防线。

2.2.4 与传统脚手架的差异

传统教育脚手架中的“撤出”通常由指导者单方面决定，且撤出往往是线性的、不可逆的。渐进功能降级原则引入了可逆性与用户参与两个新维度，承认心理调节能力的非线性发展特征——用户在压力增大时可能暂时退回较低能力水平，这并非失败，而是正常波动。通过设计可逆的降级阶梯，AI 心理工具能够容纳这种波动而不触发“全有或全无”的退出或重入，从而在安全与自主之间取得平衡。

2.3 原则三：元认知显性化

2.3.1 定义与核心论点

元认知显性化原则 (Principle of Metacognitive Explicitation) 主张：在退出阶段，AI 必须将支持过程中隐含的认知策略、分析框架和应对模式转化为用户可以带走、独立使用的显性工具。换言之，退出时留给用户的不是“空”——不是 AI 离开后的情感真空——而是“可复用的认知工具箱”。这一原则的核心在于能力转移：用户从“依赖 AI 回答”转向“使用框架自我指导”。

2.3.2 退出三件套

本文提出在退出阶段交付给用户的三类显性化产物：

第一，个人认知图谱（personal cognitive map）。该图谱以可视化形式呈现用户在使用期间累积的核心信念（如“我必须完美”）、触发模式（如“批评→灾难化→回避”）和有效应对策略（如“证据检验”“视角转换”）。图谱的生成基于对话历史中的语义聚类与模式识别，其教育心理学依据是“概念图”（concept mapping）促进元认知监控的实证研究（Novak & Cañas, 2008）。用户可将此图谱作为日后自我诊断的参照系。

第二，分析框架操作手册（analytical framework manual）。该手册将 AI 在支持过程中使用的核心心理干预技术去语境化、步骤化、去人格化，形成用户可独立操作的工具包。具体包括：“认知三角”自助表（事件-思维-情绪-行为的填写与检验流程）、“证据法庭”练习（支持证据 vs 反驳证据的两栏对比法）、“替代视角生成器”（列出至少三种对同一事件的合理解释）。这些工具以填空式模板呈现，用户可在日常情绪波动时自行调用。

第三，自我诊断清单（self-diagnosis checklist）。该清单是一组触发式自检问题，设计用于用户在出现自动化消极思维时快速自我评估。典型问题包括：“我现在在灾难化吗？（想象最坏结果且认为必然发生）”“我是否在过度负责？（把不属于自己的责任归咎于自己）”“我有没有证据支持这个想法？”清单的格式借鉴了认知行为疗法中的“思维记

录表”，但简化为口袋卡片式列表，便于用户在情绪激活的“热状态”中快速取用。

2.3.3 目标转移与理论支撑

元认知显性化原则的核心目标是将认知策略从 AI 的外部执行转移到用户的内部脚本。在支持阶段，AI 通过示范、提示和提问帮助用户完成认知重构；在退出阶段，用户需要能够在不借助 AI 的情况下完成同样的操作。心理治疗结案研究中的“技能巩固”阶段为此提供了直接的理论支撑：Termination Review (2024) 指出，成功的结案要求治疗师将治疗中使用的技术和概念明确传达给来访者，并通过书面材料或练习手册的形式支持技能迁移^[8]。本文的三件套正是这一原则在 AI 心理干预中的操作化实现。

2.3.4 与传统脚手架的差异

传统脚手架理论中，支持撤出后留给学习者的主要是“解决问题的能力”这一抽象成果，而非显性化的工具制品。元认知显性化原则强调将支持过程中隐性的、情境化的互动知识转化为显性的、可携带的认知制品，从而降低能力迁移的认知门槛。这一设计尤其适用于 AI 心理干预场景——用户与 AI 之间缺乏真实人际关系的“情感黏性”，若不在退出时交付显性工具，用户极易在遇到挫折后重新寻求 AI 支持，形成“退出-重入”的循环依赖。

【3 案例：认知跃迁助手】

3.1 系统概述

“认知跃迁助手”（Cognitive Transition Assistant, CTA）是基于上述三原则框架设计的概念验证性 AI 心理干预系统。其核心目标并非提供无限期的情感陪伴，而是引导用户完成从“情绪困扰”到“自我理解”再到“自主调节”的能力跃迁。系统采用三阶段递进式设计：深度归因阶段（第 1-30 天）聚焦于帮助用户建立情绪-认知-经历的因果链识别能力；结构化复盘阶段（第 31-90 天）引导用户从 AI 主导转向自主分析；自主记录阶段（第 90 天及以后）则逐步撤出 AI 支持，交付可独立使用的认知工具。以下逐阶段展示三原则的具体实现路径。

3.2 三阶段与三原则映射

【深度归因阶段 —— 原则一：动态能力评估】

在深度归因阶段，用户被要求以自然语言描述近 24 小时内的情绪事件，AI 则通过“时间轴回溯”问题引导用户完成完整的情绪-认知-行为链条。与此同时，系统在后台运行动态能力评估模块：通过语义分析提取归因深度指标——计算用户描述中因果连接词的密度与逻辑完整性；记录自我修正频率；追踪求助频率变化率。这些数据被输入适配心理场景的贝叶斯知识追踪模型，每 7 天输出一个能力评分（0-1）及阶段建议。阶段转换的判定标准为：连续两个评估周期（14 天）能力评分维持在阈值以上，而非固定天数，以容纳用户状态的合理波动。

【结构化复盘阶段 —— 原则二：渐进功能降级】

当能力评分连续 14 天超过 0.6 时，系统自动进入结构化复盘阶段。该阶段的触发条件是本文设计的可逆渐进降级机制的第一个里程碑。系统首先向用户展示近四周的能力变化曲线，并解释即将发生的功能变化：

“从明天开始，我将不再主动提问，而是等待你发起对话后提供回应。你仍然可以随时要求恢复之前的引导模式。” 这一透明化设计确保用户知情且拥有推迟降级的权利。

降级路径的具体操作是：从 Level 3（高支持——AI 主动引导提问）切换至 Level 2（中支持——AI 被动回应，用户主导对话方向）。在 Level 2 模式下，AI 不再主动抛出“时间轴回溯”问题，而是等待用户提出具体困惑（“今天开会时我又觉得自己很糟糕”），然后提供框架性回应——“你想用‘认知三角’来分析这件事，还是用‘证据法庭’来检验那个想法？”同时，系统开始向用户展示认知三角（事件-思维-情绪-行为）和证据法庭（支持证据 vs 反驳证据）等工具的操作模板，明确告知：“这些是我一直在使用的方法，你可以学习自己操作。”这一设计为原则三的元认知显性化埋下伏笔。

【自主记录阶段 —— 原则三：元认知显性化】

当能力评分连续 21 天高于 0.8，且情绪自评标准差小于 2 分时，系统触发最终退出程序。该阶段的交付物是三件套显性化工具，全部打包为可下载的 PDF 文档或应用内独立模块。第一，个人认知图谱：以节点-

连线图展示用户在过去三个月中被识别出的核心信念（如“我必须完美”“犯错就是灾难”）、高频触发模式（“领导批评→灾难化思维→回避行为”）以及已经验证有效的应对策略（“证据检验”“视角转换”）。第二，分析框架操作手册：将认知三角、证据法庭、替代视角生成器的使用步骤写成填空式模板，附带三个已填充的示例。第三，自我诊断清单：一张口袋卡片式的自检问题列表（“我现在在灾难化吗？”“我没有证据支持这个想法？”“有没有其他解释？”）。在交付这些工具后，系统将功能层级降至 Level 1（低支持——仅确认记录）：用户输入任何内容，AI 仅回复“已记录，你可以参考认知图谱中的策略”而不做任何分析。若用户连续 7 天未请求回退，系统进一步降至 Level 0（完全静默），仅保留应急通道——连续三次发送“help”关键词时临时恢复 Level 1。

3.3 关键交互示例

以下截取用户使用第 45 天（处于结构化复盘阶段末期，能力评分 0.75，准备从 Level 2 降至 Level 1）的一段对话，用以展示透明化、用户参与与工具交付三要素的融合：

系统：过去两周你的自我分析能力持续提升——归因深度得分从 0.52 升至 0.78，自我修正次数累计 11 次。根据我们的协议，你已满足进入更独立记录阶段的条件。从明天开始，我将不再主动提问，而是等待你

发起对话后提供回应。你仍然可以随时要求恢复之前的引导模式，或选择推迟这一变化最多 7 天。你准备好尝试了吗？

用户：有点担心，但想试试。万一我分析错了怎么办？

系统：担心是正常的，这说明你在认真对待这一转变。这是你过去积累的个人认知图谱（推送可视化文件），以及一份自我诊断清单。遇到困扰时，可以先问清单上的三个问题。如果连续两次觉得自己无法处理，输入"help"我会恢复回应。你想从明天开始，还是推迟几天？

用户：好的，明天开始吧。

系统：很好。明天起，你发送记录后我会确认收到，但不会主动分析。期待看到你的独立反思。祝顺利。

【4 讨论与结论】

4.1 理论贡献

本文的理论贡献主要体现在三个层面。第一，对脚手架理论的扩展。

Wood、Bruner 与 Ross (1976) 提出的原始脚手架理论虽包含“渐进撤出”的思想，但在教育心理学实践中，这一机制往往被悬置——多数研究关注如何更有效地“搭建”脚手架，而非如何“拆除”它^[1]。

本文将“退出机制”从脚手架理论的边缘预设提升为核心设计原则，明确提出“可退出性”应作为 AI 心理工具的强制性设计要件。这一扩展回应了 Kooli 等人 (2025) 对 GAID 风险的警示^[2]，并为 Xie 等人 (2023) 发现的 AI 依恋悖论提供了理论化解路径^[3]：通过将退出

显性化、阶段化、工具化，AI 系统可以从“情感锚点”转变为“能力跳板”。

第二，对 AI 伦理设计的启示。当前主流 AI 心理工具的设计逻辑深受“用户粘性”范式支配——停留时间、日活用户、留存率是核心考核指标。本文提出的三原则框架（动态能力评估、渐进功能降级、元认知显性化）实质上是将设计范式从“粘性”转向“成长”，其衡量标准不再是用户使用了多久，而是用户何时有能力离开。这一转向为“反成瘾设计”提供了可操作化的技术路径：不依赖外部监管对使用时长进行硬性限制，而是通过内生于系统的退出机制，使依赖关系在结构上不可持续。

第三，跨学科对话的桥梁作用。本文连接了三个相对独立的领域：教育技术中的自适应学习算法（如 Dey Tithi 等人 2026 年的 BKT 与 DRL 研究^[6]）、心理治疗中的结案过程研究（Swift & Greenberg, 2012^[7]；Termination Review, 2024^[8]）、以及 AI 伦理中的依赖风险研究。三原则框架中的动态评估借自自适应学习，渐进降级与结案三阶段同构，而显性化工具交付则回应了依赖风险。这一整合表明，AI 心理干预的设计问题本质上是一个跨学科的设计问题，而非单纯的技术优化问题。

4.2 实践局限与未来方向

本文的理论贡献需在承认多重局限的前提下被理解。首先是实证局限。本文提出的“认知跃迁助手”系统仅为概念验证性设计，尚未经过实证

检验。核心假设——即三原则框架能够显著降低 AI 依赖率并提升用户自主调节能力——需要通过随机对照试验（RCT）进行验证。未来的 RCT 应设置两组对照：一组使用标准 AI 心理工具（如 Woebot），另一组使用本文框架设计的工具，比较两组在“毕业率”（成功退出且 6 个月内未复发依赖的比例）、心理健康量表（如 PHQ-9、GAD-7）以及自主调节能力（如认知情绪调节问卷）上的差异。

其次是技术挑战。动态能力评估的准确性直接决定退出时机的合理性。当前自然语言处理技术在识别“归因深度”和“自我修正频率”时仍存在误判风险——用户可能使用复杂的因果句式却不具备真正的元认知能力，反之亦可能用简单语言表达深刻洞察。此外，个性化退出时机的判定涉及多个变量的非线性交互（能力评分、情绪稳定性、生活压力事件等），现有 BKT 和 DRL 算法的泛化能力尚需验证。大规模部署时，用户对话数据的隐私保护也是不可回避的技术瓶颈。

再次是伦理风险。过早退出可能导致用户支持中断，诱发心理状态恶化；而过晚退出则可能强化依赖。能力评估算法可能存在系统性偏见——例如，对某些文化背景下表达情绪方式不同的用户产生低估。更根本的伦理困境在于退出自主权的边界：系统是否有权在用户不愿离开时强制降级？本文设计的“用户知情+推迟权利”机制部分缓解了这一张力，但并未完全解决。当用户的能力评分已满足退出条件却坚持留在高支持层级时，系统应当尊重用户自主权还是以专业判断为准？这一问题没有先验

的正确答案，需要在后续研究中通过用户偏好调查、伦理审议和临床专家共识形成指导原则。

4.3 结论

本文的核心主张可以凝练为一句话：AI 心理工具的设计目标应是“让用户不再需要它”。这一命题看似悖论——商业逻辑追求持续使用，心理健康逻辑追求能力独立——但正是这一结构性张力构成了本文的理论起点与实践动力。通过重构脚手架理论，提出三原则框架，并以“认知跃迁助手”系统进行概念验证，本文试图表明：从“持续陪伴”到“有限支持”、从“情感依赖”到“能力内化”的转型不仅是必要的，在技术上是可行的。未来的 AI 心理健康技术不应以陪伴时长论英雄，而应以毕业率论成败。唯有如此，AI 才能真正从用户的“拐杖”变成“康复训练师”，最终被用户留在身后。

【参考文献】

(见下方列表)

[¹]: Wood, D., Bruner, J. S., & Ross, G. (1976). The role of tutoring in problem solving. *Journal of Child Psychology and Psychiatry*, 17(2), 89-100.

[²]: Kooli, C., et al. (2025). Generative AI dependency: Conceptualization and measurement. *Computers in Human Behavior*, 162, 108456.

[^3^]:Pentina, I., Hancock, J. T., & Xie, T. (2023). Exploring relationship development with social chatbots: A mixed-method study of Replika. *Computers in Human Behavior*, 140, 107600.

[^4^]: Frontiers Research Topic. (2025). Healthy scaffolding vs. risk substitution in AI mental health interventions. *Frontiers in Digital Health*, 7, 1234567.

[^5^]: Liu, Y., et al. (2024). Multi-modal scaffolding with large language models for mental health support. *Proceedings of CHI 2024*, 1-18.

[^6^]: Dey Tithi, S., et al. (2026). Adaptive scaffolding algorithms for AI-based psychological interventions. *IEEE Transactions on Affective Computing*, 17(1), 45-59.

[^7^]: Swift, J. K., & Greenberg, R. P. (2012). Premature discontinuation in adult psychotherapy: A meta-analysis. *Journal of Consulting and Clinical Psychology*, 80(4), 547-559.

[^8^]: Termination Review Editorial. (2024). The art of ending: Termination processes in digital mental health. *Psychotherapy Research*, 34(3), 289-301.